

POS Tagging

1 任务说明

本次作业的目标是实现一个词性标注 (Part-of-Speech Tagging, POS Tagging) 系统。POS Tagging 是自然语言处理中的基础任务，旨在为句子中的每个单词分配一个预定义的词性标记 (如名词、动词、形容词等)。本次作业的截止日期为 5 月 6 日 23: 59。

2 数据集

本次作业提供三个不同语言/设定的数据集，每个数据集均包含训练集 (train) 和测试集 (test)：

1. **English (EN)**: 标准英语 POS Tagging 数据。
2. **Perturbed English (EN-P)**: 对英语数据进行某种确定性扰动后得到的人造语言 (例如字母移位或字符替换)。虽然肉眼难以辨认，但其底层的语法结构与英语一致。
3. **Alien Language (AL)**: 某个人类语言经过扰动后得到的数据。我们不会告知这门语言的具体背景。

你需要针对三个数据集分别进行实验。在训练集上训练或构建模型，并在测试集上汇报 token 级别的标注准确率 (Accuracy)，即
$$\frac{\sum_{\text{sentence}_i} \sum_{\text{token}_j \in \text{sentence}_i} \mathbb{I}_{\text{predicted_tag}_j == \text{groundtruth_tag}_j}}{\sum_i \text{total_tokens}(\text{sentence}_i)}$$

3 实验要求

3.1 模型选择

你可以选择以下任意一种或多种方法来实现你的系统：

- **统计方法**：如隐马尔可夫模型 (HMM)、条件随机场 (CRF) 等。

- **神经网络方法**：如 RNN、LSTM、BERT-based models 等。
- **大语言模型 (LLM)**：如通过 Prompt Engineering 或 Fine-tuning 利用 GPT、Llama 等模型进行标注。

3.2 Baseline 要求

除了你主要研究的方法外，你**必须**实现并汇报 **Majority Voting** 这一 Baseline 的结果，即为每个单词分配训练集中出现频率最高的词性 (Simple Most Frequent Class)。

请在实验报告中明确对比你的方法与 Baseline 在三个测试集上的表现。你使用的方法须在 **EN** 与 **EN-P** 两个测试集中比 Majority Voting Baseline 的表现更好。对于 AL 测试集，若你的方法表现低于 Baseline，请解释可能的原因。

4 实验报告撰写要求

实验报告需详细说明你的实验过程与结果。报告必须包含以下内容：

- **方法介绍**：详细描述你所采用的词性标注方法（统计方法、神经网络或大语言模型等）及其实现细节。
- **实验结果**：汇报主模型以及 Baseline 模型在三个数据集（EN, EN-P, AL）测试集上的表现（Accuracy）。建议使用表格形式进行对比。
- **结果分析**：对实验结果及所用方法进行深入分析。我们鼓励任何具有启发性和有价值的讨论（如不同数据集表现差异的原因、模型失败案例分析等），优秀的分析将获得酌情加分。
- **代码与运行说明**：简要说明提交的代码结构、主要文件功能以及具体的运行环境与命令。
- **AI 使用声明**：如实填写并在报告中包含“AI 使用声明”一节（见 L^AT_EX 模板）。

报告要求：

- 必须使用本次作业提供的 L^AT_EX 模版撰写。

- 实验报告的 L^AT_EX 模板文件已放置在作业文件夹中，请在此基础上进行撰写。(编译器请使用 XeLaTeX)
- 推荐使用 PKUTeX (<https://latex.pku.edu.cn/>) 在线撰写，无需配置本地环境。

5 提交要求与迟交政策

提交内容应包含代码、实验报告以及（可选的）模型权重：

- **代码封装**：请将所有代码打包在一个文件夹内。根目录下必须包含一个 README.md 文件，详细说明环境配置（如 requirements.txt）、运行脚本的命令以及如何重现你的实验结果。
- **实验报告**：需详细描述你的方法设计、Baseline 实现细节、实验结果对比及分析。
- **模型权重**：如果训练了神经网络模型，请勿直接在作业系统中上传体积庞大的权重文件。请将权重上传至 **北大网盘** (<https://disk.pku.edu.cn/>)，并在报告或 README 中提供下载链接。
- **安全提示**：如果你使用 LLM 调用 API 进行实验，请在提交代码前**务必删除所有的 API Key**，以免造成个人隐私泄露或财产损失。

迟交的作业每晚交一天，将从最终成绩中扣除 5%。在截止日期一周后（5 月 13 日 23:59），将不再接受任何作业提交。你可以无限次地重新提交，你的作业提交时间将以你最后一次在课程系统中提交的时间为准。因此，除非你确信新的提交内容有了显著改进，足以弥补因迟交而扣除的分数，否则请不要在截止日期当天的午夜之后重新提交。提交时间没有任何商量的余地，因迟交而扣除的分数将四舍五入至最接近的整数。

6 联系助教

- ma_tianyao@stu.pku.edu.cn（马天尧）
- liaozy@stu.pku.edu.cn（廖致远）
- linjiuheng@stu.pku.edu.cn（林九衡）