

FNLP 2026 Assignment 3 实验报告

姓名：林乐天

学号：2300012154

1. 实验任务

本次实验的目标是在 MuSiQue 多跳问答数据上完成多跳证据检索 (multi-hop evidence retrieval)。对于每个问题，系统需要从全局段落语料库中返回 Top-5 段落，并使用 Recall@5 评价检索结果是否覆盖了标准支持性证据。

2. 数据集与评测方式

实验使用课程提供的 MuSiQue 数据处理结果：

1. 全局语料库：data/corpus.jsonl，共 21,100 个段落。
2. 测试集：
 - data/test_2hop.jsonl：200 个 2-hop 问题
 - data/test_3hop.jsonl：200 个 3-hop 问题
 - data/test_4hop.jsonl：200 个 4-hop 问题

从现有测试文件可以看到，每个问题的标准证据段落数与 hop 数一致，因此：

1. 2-hop 问题平均需要命中 2 个 gold 段落
2. 3-hop 问题平均需要命中 3 个 gold 段落
3. 4-hop 问题平均需要命中 4 个 gold 段落

评测指标为 Recall@5。对每个问题，记标准支持段落集合为 $Gold(q)$ ，检索出的前 5 个段落为 $Retrieved_5(q)$ ，则：

$$Recall@5(q) = \frac{|Retrieved_5(q) \cap Gold(q)|}{|Gold(q)|}$$

最终结果为所有问题 Recall@5 的平均值。该指标很适合多跳证据检索，因为它直接衡量系统是否覆盖了推理链所需的所有关键段落。

3. BM25 稀疏检索

3.1 方法原理

BM25 是经典的词项匹配检索方法，本质上仍然是基于词袋模型的相关性打分。它综合考虑：

1. 查询词在文档中的出现频次
2. 查询词在整个语料中的逆文档频率 (IDF)
3. 文档长度归一化

其核心思想是：如果问题中的关键词在某段落中多次出现，且这些词在整个语料中较少见，那么该段落更可能与问题相关。

3.2 实现细节

scripts/run_bm25.py 实现了 BM25 基线，主要细节如下：

1. 使用 rank_bm25.BM25Okapi 构建索引。
2. 将每个段落组织为 title + ": " + text 的形式参与索引。这样做的原因是标题往往包含实体名，对多跳检索尤其重要。
3. 对文本进行正则分词，只保留字母、数字和部分特殊形式（如连字符、C++、C#）。
4. 全部转为小写后，去除英文停用词。
5. 使用 PorterStemmer 做词干化，降低词形变化带来的影响。
6. 对每个问题直接检索 Top-5 段落，并保存为 JSONL 文件。

这套实现本质上是一个比较强的 lexical baseline。标题拼接、停用词过滤和词干化都能提高实体匹配和关系词匹配的效果。

3.3 BM25 实验结果

根据仓库中已有预测文件 outputs/bm25/predictions_*hop.jsonl，使用 scripts/evaluate.py 计算得到：

方法	2-hop	3-hop	4-hop	三组平均
BM25	0.4975	0.3783	0.2150	0.3636
课程给定 Baseline	0.3700	0.2700	0.1500	0.2633

可以看到，现有 BM25 实现明显超过了课程提供的稀疏检索 baseline，说明该实现中的文本预处理和标题增强是有效的。

4. Dense Retrieval 稠密检索

4.1 方法原理

稠密检索的核心思想是：使用预训练文本嵌入模型将问题和段落编码到同一个向量空间中，再通过向量相似度进行检索。与 BM25 依赖显式词项重合不同，稠密检索更擅长处理：

1. 近义表达
2. 改写表达
3. 词面不完全重合但语义接近的证据匹配

在多跳问答场景中，问题往往包含较长的关系链，词面形式比较复杂，因此稠密检索通常比纯词项匹配更有优势。

4.2 实现细节

仓库中的 scripts/build_index.py 和 scripts/run_dense.py 实现了稠密检索流程，主要细节如下：

1. 由于算力限制，难以运行更大的模型，实际使用的嵌入模型是 BAAI/bge-large-en-v1.5。
2. 语料编码阶段将每个段落表示为 title + ": " + text，与 BM25 保持一致。

3. 查询端使用指令前缀：Represent this sentence for searching relevant passages:
4. 使用 SentenceTransformer 编码，max_seq_length=512。
5. 对向量做 normalize_embeddings=True 归一化。
6. 使用 FAISS 的 IndexFlatIP 建立向量索引；在向量归一化后，内积检索等价于余弦相似度检索。
7. build_index.py 支持多进程/多 GPU 分块编码全文语料，先保存各分块的 .npy 文件，再拼接为完整的 corpus_embeddings.npy 并写入 corpus.faiss。

这一实现没有进行监督训练或额外微调，属于预训练嵌入模型的零样本检索（zero-shot retrieval）。

4.3 Dense 实验结果

根据已有预测文件 outputs/dense/predictions_*hop.jsonl，评测结果如下：

方法	2-hop	3-hop	4-hop	三组平均
Dense Retrieval	0.6300	0.5050	0.2963	0.4771
课程给定 Baseline	0.6000	0.5300	0.3000	0.4767

从平均值上看，当前稠密检索结果 0.4771 略高于课程 baseline 的 0.4767。不过分 hop 观察可以发现：

1. 2-hop 结果优于 baseline
2. 3-hop 和 4-hop 略低于 baseline
3. 由于评分规则按三组平均 Recall@5 计算，因此整体上仍然达到 baseline 水平

5. 结果对比与分析

5.1 总体对比

将两种方法放在一起比较：

方法	2-hop	3-hop	4-hop	三组平均
BM25	0.4975	0.3783	0.2150	0.3636
Dense Retrieval	0.6300	0.5050	0.2963	0.4771
Dense - BM25	+0.1325	+0.1267	+0.0813	+0.1135

可以得到几个明显结论：

1. 稠密检索在三个 hop 设置下都优于 BM25。
2. 两种方法的性能都会随着 hop 数增加而明显下降。
3. Dense 相对 BM25 的优势在 2-hop 和 3-hop 时更明显，到 4-hop 时优势变小。

5.2 为什么 hop 数越高越难

随着 hop 数增加，问题需要覆盖的 gold 段落数量也增加，但系统始终只能返回 Top-5 段落，因此检索难度显著提升：

1. 对 2-hop 问题，只要命中 2 个关键段落即可获得满分。
2. 对 4-hop 问题，Top-5 中必须尽量容纳 4 个 gold 段落，容错空间只剩 1 个干扰项。
3. 一旦某一步桥接实体没有被正确召回，整条多跳链条的证据覆盖率就会明显下降。

因此，4-hop 场景不仅需要更强的相关性判断，还要求模型在多个证据点之间保持较稳定的覆盖能力。

5.3 稠密检索优于 BM25 的原因

Dense Retrieval 的主要优势体现在以下几方面：

1. 能处理问题中的改写表达和抽象关系，不完全依赖关键词重合。
2. 能利用上下文语义，把“地点、人物、组织、事件”之间的关联映射到同一向量空间。
3. 能显著减少完全检索失败的情况。

从现有结果统计来看，Dense 的 zero-recall 数量明显少于 BM25：

hop	BM25 零命中数	Dense 零命中数
2-hop	44	14
3-hop	43	14
4-hop	71	34

这说明稠密检索更不容易出现“前五个段落一个标准证据都没有”的灾难性错误。

5.4 BM25 仍然有效的场景

尽管整体性能较低，BM25 在某些场景仍然很有竞争力：

1. 问题中包含罕见实体名、作品名、地名时，词面精确匹配非常有效。
2. 如果 gold 段落标题中直接包含问题中的核心实体，BM25 往往能快速命中。
3. 在某些长链条问题中，BM25 对少数关键桥接词的抓取反而比稠密检索更稳定。

换言之，BM25 的优势不在“语义泛化”，而在“实体对齐”和“字面锚定”。

6. Case Study

6.1 BM25 检索成功但 Dense 表现较差

案例一：县城与县治的精确匹配

- 问题：What is the capital of the county where Fort Deposit is located?
- Gold 段落：Fort Deposit, Alabama、Hayneville, Alabama
- 结果：BM25=1.0, Dense=0.5

分析：

1. Fort Deposit, Alabama 段落中明确出现了 Lowndes County。
2. Hayneville, Alabama 段落中明确出现了 county seat of Lowndes County。
3. BM25 通过 Fort Deposit、county、capital/county seat 这类词面线索直接命中两个 gold。
4. Dense 只命中了第一个 gold，后续却被多个含有 Fort 或 county seat 的相似地理段落干扰，例如 Fort Scott National Cemetery 等。

这说明在实体名非常明确、推理链几乎可以由字面信息串联时，BM25 的精确匹配有明显优势。

案例二：稀有实体链导致语义检索漂移

- 问题：What forced the departure from the country responsible for Phoe Pyonn Cho of the people once defied by new coinage?
- Gold 段落：Phoe Pyonn Cho、Ottoman Empire、Myanmar
- 结果：BM25=0.6667，Dense=0.0

分析：

1. 问题中包含很罕见的实体 Phoe Pyonn Cho，BM25 能借助这个强词面信号命中对应电影条目。
2. Ottoman Empire 段落中直接提到 Somali Muslim Ajuran Empire defied the Portuguese。
3. Myanmar 的 gold 段落中又直接出现 defeated the Portuguese 的描述。
4. Dense 在这个问题上几乎完全漂移到了 North Korea、Korean War 等主题相近但实体链错误的段落。

这个案例表明：当问题包含多个冷门实体且依赖严格的实体跳转时，稠密向量很容易被抽象语义带偏，而 BM25 更依赖“关键词是否真的出现过”。

6.2 Dense 检索成功但 BM25 失败

案例三：表面词误导 BM25

- 问题：When did the crowning of the person under whom the Chapter House was built happen?
- Gold 段落：两个 Westminster Abbey 相关段落
- 结果：BM25=0.0，Dense=1.0

分析：

1. 问题里出现 crowning，BM25 被词面上相近的 Crown 误导，返回了 A Crown of Swords 等完全不相关的条目。
2. Dense 则能够把 Chapter House、Henry III、coronation 这几个语义片段关联起来，成功找回两个 Westminster Abbey 段落。

这说明 BM25 的局限在于：它只能利用表面词项，无法判断“看起来像相关词”的结果在语义上是否真的相关。

案例四：多跳关系需要语义桥接

- 问题：When was the Palau de la Generalitat constructed in the city where Martin from where Jaulin is located died?
- Gold 段落：Jaulín、Martin of Aragon、Gothic architecture
- 结果：BM25=0.0, Dense=1.0

分析：

1. 这道题需要完成 Jaulín -> Aragon -> Martin of Aragon -> Palau de la Generalitat 的多步桥接。
2. BM25 返回了大量 Barcelona Metro 之类的段落，说明它被 Palau、city 等表面词牵引到了错误语境。
3. Dense 能把 Jaulín、Aragon、建筑历史等语义线索放到同一表示空间中，因此成功覆盖 3 个 gold 段落。

这个案例反映出稠密检索对复杂关系链更敏感，尤其适合处理词面不完全重合的桥接式问题。

7. 进一步讨论

从现有结果看，Dense 虽然整体优于 BM25，但在 4-hop 上仍然只有 0.2963，说明仅靠单轮 Top-5 检索仍然不足以稳定覆盖长推理链。后续可以考虑以下改进方向：

1. **稀疏 + 稠密融合检索**：例如将 BM25 与 Dense 的结果做加权融合或 Reciprocal Rank Fusion，兼顾实体精确匹配和语义召回。
2. **重排序 (reranking)**：先用 BM25/Dense 召回更多候选，再使用 cross-encoder 对候选段落做精排。
3. **问题分解或迭代检索**：多跳问题可以先显式拆分成多个子问题，再逐跳扩展检索，而不是只做一次性 Top-5 检索。
4. **更强或更适配的嵌入模型**：当前方法没有微调，如果使用针对检索任务训练过的模型，或在 MuSiQue 上进行对比学习微调，结果还有提升空间。

8. 结论

本次作业完成了 BM25 稀疏检索与 Dense Retrieval 稠密检索的实验分析。

1. BM25 在三个测试集上的 Recall@5 分别为 0.4975 / 0.3783 / 0.2150，平均 0.3636，显著超过课程给定的稀疏 baseline。
2. Dense Retrieval 在三个测试集上的 Recall@5 分别为 0.6300 / 0.5050 / 0.2963，平均 0.4771，整体上略高于课程给定的稠密 baseline。
3. Dense 在所有 hop 上都优于 BM25，说明语义表示对多跳证据检索确实更有效。
4. 但随着 hop 数增加，两类方法都会快速退化，说明多跳证据覆盖仍是当前系统的主要瓶颈。